

## 8. Métodos de Descida

---

### 8.1. Método do Gradiente (descida máxima)

---

Considere-se a função  $f(x)$  desenvolvida em série de Taylor, desprezando-se os termos de ordem  $\geq 2$  :

$$f(\mathbf{x} + \delta \mathbf{x}) = f(\mathbf{x}) + \nabla^T f(\mathbf{x}) \delta \mathbf{x}$$

Deseja-se estabelecer uma sequência de valores do vetor  $\mathbf{x}$ , que convirja para que  $\mathbf{x}^*/f(\mathbf{x}^*)$  seja mínimo. Denominando-se  $\mathbf{x}^{(k)}$  como o k-ésimo valor do vetor  $\mathbf{x}$  e fazendo  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \delta \mathbf{x}^{(k)}$ , tem-se :

$$f(\mathbf{x}^{(k+1)}) = f(\mathbf{x}^{(k)}) + \nabla^T f(\mathbf{x}^{(k)}) (\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)})$$

Se a sequência  $\{\mathbf{x}^{(k)}\}$  é estabelecida no sentido de minimizar  $f(\mathbf{x})$  e, se além disso, deseja-se uma redução máxima possível entre dois valores consecutivos de  $f(\mathbf{x})$ , deve-se ter :

$$\max \{f(\mathbf{x}^{(k)}) - f(\mathbf{x}^{(k+1)})\} = \max \{-\nabla^T f(\mathbf{x}^{(k)}) \delta \mathbf{x}^{(k)}\}$$

i.e.,  $-\nabla^T f(\mathbf{x}^{(k)})$  e  $\delta \mathbf{x}^{(k)}$  devem ser colineares :

$$\delta \mathbf{x}^{(k)} = -\alpha \nabla f(\mathbf{x}^{(k)})$$

ou ainda :

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f(\mathbf{x}^{(k)}) \text{ (eq. de busca)}$$

onde:

$\alpha^{(k)}$  : passo (k-ésima estimativa)

Portanto, a direção de busca que produz a máxima descida é  $d^{(k)} = -\nabla f(x^{(k)})$ , no ponto  $x = x^{(k)}$ . O cálculo de  $d^{(k)}$  corresponde ao 1º passo do método.

O 2º passo consiste em determinar  $\alpha^{(k)} \geq 0 / f(\mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)})$  seja mínimo. Esse processo é chamado de “busca linear exata”. O 3º passo corresponde à aplicação da equação de busca, concluindo assim a k-ésima iteração.

Substituindo  $\delta \mathbf{x}_p = -\alpha \nabla f(\mathbf{x}_p)$  na expansão em série de Taylor:

$$f(\mathbf{x}_p) - f(\mathbf{x}_{p+1}) = \alpha \nabla^T f(\mathbf{x}_p) \cdot \nabla f(\mathbf{x}_p)$$

Logo:

$\alpha > 0 \Rightarrow$  minimização

$\alpha < 0 \Rightarrow$  maximização

A escolha do passo  $\alpha$  é portanto de fundamental importância para a convergência do método.

### 8.1.1 Exemplo:

---

Minimizar  $f(x) = x_1^2 - 2x_1 + x_2^2$

O vetor  $\mathbf{x}$  é dado por:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

O cálculo das derivadas parciais leva a:

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 - 2 \\ 2x_2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Como  $\mathbf{x}^T \nabla^2 f(\mathbf{x}) \mathbf{x} \geq 0 \Rightarrow f$  possui um mínimo e a condição  $\nabla f(x) = 0$  é necessária e suficiente para garantir que este é o mínimo global ( $f$  é convexa). Aplicando então essa condição, obtém-se:

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^* = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

onde o asterisco indica a situação de otimalidade.

Aplicando o método do gradiente para resolver o problema acima, a fim de estudar o seu desempenho quanto à convergência, tem-se:

$$\mathbf{x}^{(p+1)} = \mathbf{x}^{(p)} - \alpha \begin{bmatrix} 2x_1 - 2 \\ 2x_2 \end{bmatrix}^{(p)}$$

Adotar-se-á como ponto de partida o vetor:

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^{(0)} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

Em seguida, alguns valores de  $\alpha$  serão testados:

a)  $\alpha = 1,5$

1ª iteração:

$$x_1^{(1)} = x_1^{(0)} - 1,5 \left( \frac{\partial f}{\partial x_1} \right)^{(0)} = -1 - 1,5 \cdot (-4) = 5$$

$$x_2^{(1)} = x_2^{(0)} - 1,5 \left( \frac{\partial f}{\partial x_2} \right)^{(0)} = 1 - 1,5 \cdot (2) = -2$$

2ª iteração:

$$x_1^{(2)} = x_1^{(1)} - 1,5 \left( \frac{\partial f}{\partial x_1} \right)^{(1)} = -7$$

$$x_2^{(2)} = x_2^{(1)} - 1,5 \left( \frac{\partial f}{\partial x_2} \right)^{(1)} = 4$$

3ª iteração:

$$x_1^{(3)} = -7 - 1,5 \cdot (-16) = 17$$

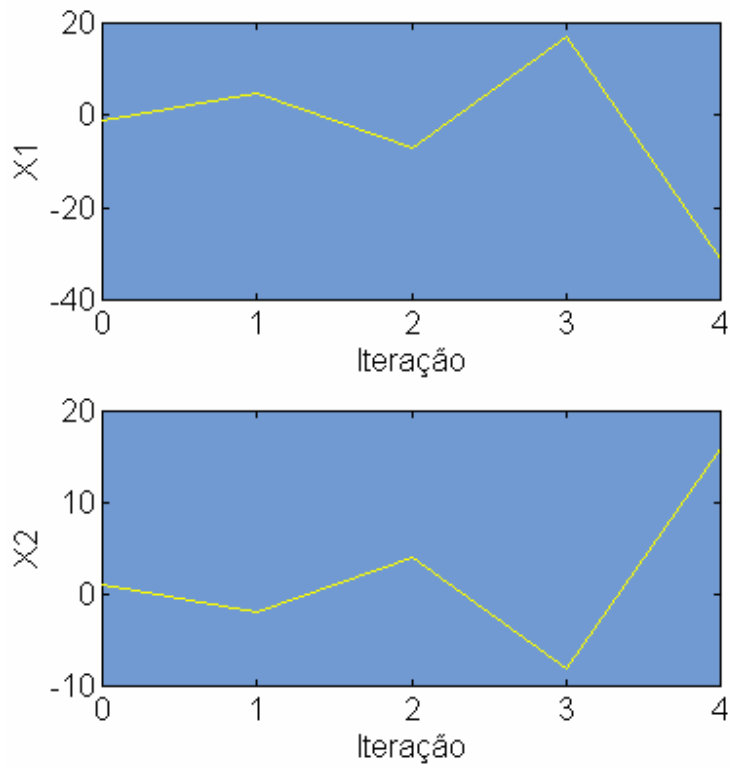
$$x_2^{(3)} = 4 - 1,5 \cdot (8) = -8$$

4ª iteração:

$$x_1^{(4)} = 17 - 1,5 \cdot (32) = -31$$

$$x_2^{(4)} = -8 - 1,5 \cdot (-16) = 16$$

Os gráficos de  $x_1$  e  $x_2$ , em função do contador de iterações, são mostrados abaixo:



b)  $\alpha = 0,75$ :

Depois de efetuados os cálculos, obtém-se:


$$x_1^{(1)} = 2; \quad x_2^{(1)} = -0,5$$

$$x_1^{(2)} = 0,5; \quad x_2^{(2)} = 0,25$$

$$x_1^{(3)} = 1,25; \quad x_2^{(3)} = -0,125$$

$$x_1^{(4)} = 0,875; \quad x_2^{(4)} = 0,0625$$

Esses valores correspondem aos gráficos abaixo:



Nesse caso, nota-se que, após algumas iterações, a convergência é obtida para  $x_1 = 1$  e  $x_2 = 0$ . Observa-se que, se o valor de  $\alpha$  for escolhido no intervalo  $0 < \alpha < 0,5$ , a convergência é obtida de forma tangencial; se, entretanto, adotar-se  $\alpha = 0,5$ , apenas uma iteração é suficiente para alcançar a solução:

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^{\text{ot}} = \begin{bmatrix} -1 \\ 1 \end{bmatrix} - 0,5 \cdot \begin{bmatrix} -4 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

### 8.1.2 Função objetivo quadrática

---

Seja  $f(\mathbf{x}) = \mathbf{x}^T \mathbf{C} \mathbf{x} + \mathbf{b}^T \mathbf{x} + a$

Conforme calculado na seção 5.3.4, o vetor gradiente  $\nabla f(\mathbf{x})$  é dado por:

$$\nabla f(\mathbf{x}) = 2\mathbf{C}\mathbf{x} + \mathbf{b}$$

A busca linear exata exige que:

$$\nabla f(\mathbf{x} + \alpha \cdot \mathbf{d}) = 2\mathbf{C}\mathbf{x} + 2\alpha \cdot \mathbf{C}\mathbf{d} + \mathbf{b} = \mathbf{0}$$

ou ainda:

$$2\alpha \cdot \mathbf{C}\mathbf{d} = -\nabla f(\mathbf{x})$$

Ou:

$$2\alpha \cdot \begin{bmatrix} c_{11}d_1 + \dots + c_{1n}d_n \\ \vdots \\ c_{n1}d_1 + \dots + c_{nn}d_n \end{bmatrix} = - \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$$

Multiplicando ambos os membros por  $\mathbf{d}^T$  e explicitando  $\alpha$ , obtém-se:

$$\alpha = \frac{-1}{2} \frac{\mathbf{d}^T \cdot \nabla f(\mathbf{x})}{\mathbf{d}^T \cdot \mathbf{C} \cdot \mathbf{d}}$$

Como no método do gradiente  $\mathbf{d} = -\nabla f(\mathbf{x})$ , tem-se:

$$2\alpha \cdot \mathbf{C} \nabla f(\mathbf{x}) = \nabla f(\mathbf{x})$$

$$\alpha = \frac{1}{2} \frac{\nabla^T f(\mathbf{x}) \cdot \nabla f(\mathbf{x})}{\nabla^T f(\mathbf{x}) \cdot \mathbf{C} \cdot \nabla f(\mathbf{x})}$$

## 8.2 Método de Newton

---

### 8.2.1 Função quadrática

---

Seja  $f$  uma função quadrática com matriz hessiana  $\mathbf{G} = 2 \cdot \mathbf{C}$ , definida positiva.

Partindo de  $\mathbf{x}^{(0)} \in \Re^n$  arbitrário, a direção  $\mathbf{d} \in \Re^n$  dada por:

$$\mathbf{d} = -\mathbf{G}^{-1}(\mathbf{G} \cdot \mathbf{x}^{(0)} + \mathbf{b}) = -\mathbf{G}^{-1} \nabla f(\mathbf{x}^{(0)})$$

determina diretamente o minimizador global de  $f$ , através de:

$$\mathbf{x}^{ot} = \mathbf{x}^{(0)} + \mathbf{d}$$

Demonstração:

Seja  $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} + \mathbf{b}^T \mathbf{x} + a$ . Então  $\nabla f(\mathbf{x}) = \mathbf{G} \mathbf{x} + \mathbf{b}$  e, para  $\mathbf{x}^{ot} = \mathbf{x}^{(0)} + \mathbf{d}$ , tem-se:

$$\nabla f(\mathbf{x}^{ot}) = \mathbf{G}(\mathbf{x}^{(0)} + \mathbf{d}) + \mathbf{b} = \mathbf{G}[\mathbf{x}^{(0)} - \mathbf{G}^{-1}(\mathbf{G} \mathbf{x}^{(0)} + \mathbf{b})] + \mathbf{b} = \mathbf{G} \mathbf{x}^{(0)} - (\mathbf{G} \mathbf{x}^{(0)} + \mathbf{b}) + \mathbf{b} = \mathbf{0}$$

Portanto,  $\mathbf{x}^{ot}$  é um minimizador global. Notar que, para determinar  $\mathbf{x}^{ot}$ , é suficiente encontrar a direção de busca  $\mathbf{d}$ , o que equivale a resolver o sistema linear dado por:

$$\mathbf{G} \mathbf{d} = -\nabla f(\mathbf{x}^{(0)})$$

partindo de qualquer ponto  $\mathbf{x}^{(0)}$ .

## 8.2.2 Função não-quadrática

---

Nesse caso, considera-se uma aproximação quadrática para a função, entre dois pontos consecutivos da sequência  $\{\mathbf{x}^{(k)}\}$ :

$$f(\mathbf{x}^{(k)} + \mathbf{d}^{(k)}) = f(\mathbf{x}^{(k)}) + \nabla^T f(\mathbf{x}^{(k)}) \mathbf{d}^{(k)} + \frac{1}{2} \mathbf{d}^{(k),T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{d}^{(k)}$$

Essa expressão define uma função quadrática  $q(\mathbf{d})$ , caracterizada por:

$$q(\mathbf{d}) = f(\mathbf{x}^{(k)} + \mathbf{d})$$

t.q.:

$$\begin{cases} q(\mathbf{0}) = f(\mathbf{x}^{(k)}) \\ \nabla q(\mathbf{0}) = \nabla f(\mathbf{x}^{(k)} + \mathbf{d}) \Big|_{\mathbf{d}=\mathbf{0}} = \nabla f(\mathbf{x}^{(k)}) \\ \nabla^2 q(\mathbf{0}) = \nabla^2 q(\mathbf{d}) \Big|_{\mathbf{d}=\mathbf{0}} = \nabla^2 f(\mathbf{x}^{(k)}) \end{cases}$$

sendo:

$$q(\mathbf{d}) = f(\mathbf{x}^{(k)}) + \nabla^T f(\mathbf{x}^{(k)}) \mathbf{d}^{(k)} + \frac{1}{2} \mathbf{d}^{(k),T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{d}^{(k)}$$

$$q(\mathbf{d}) = q(\mathbf{0}) + \nabla^T q(\mathbf{0}) \mathbf{d}^{(k)} + \frac{1}{2} \mathbf{d}^{(k),T} \nabla^2 q(\mathbf{0}) \mathbf{d}^{(k)}$$

De acordo com o teorema do item anterior, a direção ótima de busca do mínimo de  $q(\mathbf{d})$  é dada por:

$$\mathbf{d}^{\text{ot}} = -\left[\nabla^2 f(\mathbf{x}^{(k)})\right]^{-1} \cdot \left\{ \nabla^2 f(\mathbf{x}^{(k)}) \cdot \mathbf{d}^{(0)} + \nabla f(\mathbf{x}^{(k)}) \right\}$$

Partindo de  $\mathbf{d}^{(0)} = \mathbf{0}$ , tem-se que a direção ótima de busca para a k-ésima iteração é dada por:

$$\mathbf{d}^{(k)} = -\left[\nabla^2 f(\mathbf{x}^{(k)})\right]^{-1} \cdot \nabla f(\mathbf{x}^{(k)})$$

### 8.2.3 Algoritmo

---

Seja  $\mathbf{x}^{(k)}$  tal que  $\nabla f(\mathbf{x}^{(k)}) \neq \mathbf{0}$ . O ponto  $\mathbf{x}^{(k+1)}$  pode ser obtido através dos seguintes passos:

1 Determinar  $\mathbf{d}^{(k)}$  de acordo com:

$$\nabla^2 f(\mathbf{x}^{(k)}) \cdot \mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$



2 Determinar  $\alpha^{(k)}$  através de uma busca linear.

3 Calcular  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \cdot \mathbf{d}^{(k)}$

4 Retornar ao passo 1, caso não se tenha atingido a convergência.

### 8.3 Métodos quase-Newton

---

Os métodos do gradiente e de Newton possuem direções de busca definidas por:

$$\mathbf{d}^{(k)} = -\mathbf{H}^{(k)} \cdot \nabla f(\mathbf{x}^{(k)})$$

sendo que, no método do gradiente,  $\mathbf{H}^{(k)} = \mathbf{E}$  (matriz identidade); no método de Newton,  $\mathbf{H}^{(k)} = [\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$ .

A grande vantagem do método de Newton sobre o método do gradiente reside no fato de sua equação de busca ser derivada de uma aproximação quadrática da função objetivo; no método do gradiente, essa aproximação é linear. Isso faz com que a convergência do método de Newton seja mais rápida. Em contrapartida, o cálculo de sua direção de busca, a cada iteração, requer a avaliação da matriz hessiana, bem como a solução de um sistema de equações lineares.

Os métodos quase-Newton também possuem direção de busca definida pela equação acima, sendo que a matriz  $\mathbf{H}$  não chega a ser tão simples como a matriz identidade, nem tão completa como a matriz hessiana. É evidente que, para se obter uma convergência melhor que a do método do gradiente, alguma informação de segunda ordem precisa ser utilizada. Deve-se ainda atentar para o fato de que, se  $\mathbf{H}^{(k)}$  é simétrica e definida positiva, a direção  $\mathbf{d}^{(k)}$  é uma direção de descida.

#### 8.3.1 Método de Davidon-Fletcher-Powell

---

Sejam o vetor  $\mathbf{x}^{(0)}$  e a matriz definida positiva  $\mathbf{H}^{(0)}$ , arbitrários. Se  $\nabla f(\mathbf{x}^{(k)}) \neq 0$ , uma melhor estimativa de  $\mathbf{x}^{ot}$ , digamos  $\mathbf{x}^{(k+1)}$ , pode ser obtida através dos seguintes passos:

1 Calcular  $\mathbf{d}^{(k)} = -\mathbf{H}^{(k)} \cdot \nabla f(\mathbf{x}^{(k)})$

2 Determinar  $\alpha^{(k)}$  através de uma busca linear e calcular  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \cdot \mathbf{d}^{(k)}$ .

Sucessivas melhores estimativas podem ser obtidas através de uma atualização da matriz  $\mathbf{H}$ , de acordo com o passo seguinte.

3 Definindo  $\mathbf{p}^{(k)} = \alpha^{(k)} \cdot \mathbf{d}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ ,  $\mathbf{q}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$ , calcular:

$$\mathbf{H}^{(k+1)} = \mathbf{H}^{(k)} + \frac{\mathbf{p}^{(k)} \cdot \mathbf{p}^{(k)T}}{\mathbf{p}^{(k)T} \cdot \mathbf{q}^{(k)}} - \frac{\mathbf{H}^{(k)} \mathbf{q}^{(k)} \cdot \mathbf{q}^{(k)T} \mathbf{H}^{(k)}}{\mathbf{q}^{(k)T} \mathbf{H}^{(k)} \mathbf{q}^{(k)}}$$

O número de multiplicações envolvidas em cada atualização da matriz  $\mathbf{H}$ , pode ser determinado como segue:

$$\mathbf{p} \cdot \mathbf{p}^T : n^2$$

$$\mathbf{p}^T \cdot \mathbf{q} : n$$

$$\mathbf{q}^{(k)T} \mathbf{H}^{(k)} \mathbf{q}^{(k)} : n^2 + n$$

$$(\mathbf{H} \cdot \mathbf{q}) \cdot \mathbf{q}^T \cdot \mathbf{H} : (n^2) + n^2 + n^2 = 2n^2$$

-----

$$\text{Total por iteração : } 4n^2 + 2n$$

Uma vez que o cálculo de  $\mathbf{G}^{-1}$ , no método de Newton, envolve  $n^3$  multiplicações, para problemas de grande porte, o método de Davidon-Fletcher-Powell consome muito menos tempo computacional. Pode-se ainda mostrar, para  $f$  quadrática, que:

- Se  $\mathbf{H}^{(k)}$  é positiva definida,  $\mathbf{H}^{(k+1)}$  também o é.
- Os vetores  $\mathbf{d}^{(0)}, \dots, \mathbf{d}^{(n-1)}$  são L.I.
- $\mathbf{x}^{(n)} = \mathbf{x}^{ot}$
- $\mathbf{H}^{(n)} = \mathbf{G}^{-1}$

### 8.3.2 Método de Broyden-Fletcher-Goldfarb-Shanno

---

$$\mathbf{H}^{(k+1)} = \mathbf{H}^{(k)} + \left( 1 + \frac{\mathbf{q}^{(k)T} \mathbf{H}^{(k)} \mathbf{q}^{(k)}}{\mathbf{p}^{(k)T} \cdot \mathbf{q}^{(k)}} \right) \frac{\mathbf{p}^{(k)} \cdot \mathbf{p}^{(k)T}}{\mathbf{p}^{(k)T} \cdot \mathbf{q}^{(k)}} - \frac{\mathbf{p} \mathbf{q}^{(k)T} \mathbf{H}^{(k)} + \mathbf{H}^{(k)} \mathbf{q}^{(k)} \mathbf{p}^T}{\mathbf{p}^{(k)T} \mathbf{q}^{(k)}}$$